

# Lista\_3

## Analiza przeżycia

Olga Foriasz

2025-10-15

### LISTA 3

#### Zadanie 1a

Dane bierzeny z zadania 3 z listy 2. Wyznamy oszacowania największej wiarygodności średniego czasu do remisji choroby dla pacjentów leczonych lekiem A oraz pacjentów leczonych lekiem B.

```
T_a = sum(grupa_A[1:10]) + t0*(n-R)
T_b = sum(grupa_B[1:10]) + t0*(n-R)

theta_a <- R/T_a
theta_b <- R/T_b
```

Średni czas do remisji dla leku A wynosi: 0.7034414, natomiast dla leku B: 0.7430155

#### Zadanie 1b

Wyznamy realizację przedziału ufności na poziomie  $1-\alpha$  dla średniego czasu do remisji choroby osobno dla pacjentów leczonych lekiem A oraz lekiem B (dane z listy 2. z zadania 3.) Zakładamy, że są to zmienne z rozkładu wykładniczego. Za  $\alpha$  przyjmujemy kolejno  $\alpha=0.05$  oraz  $\alpha=0.01$ .

```
library(binom)

## dla alfy = 0.05
alfa=0.05
T.L <- binom.confint(R,n,conf.level=1-alfa, methods="exact")$lower
T.U <- binom.confint(R,n,conf.level=1-alfa, methods = "exact")$upper

TL1= (-log(1-T.L))/t0
TU1= (-log(1-T.U))/t0

TL1 = round(TL1,2)
TU1 = round(TU1,2)
## dla alfy = 0.01
alfa=0.01
T.L <- binom.confint(R,n,conf.level=1-alfa, methods="exact")$lower
T.U <- binom.confint(R,n,conf.level=1-alfa, methods = "exact")$upper
```

```
TL2= (-log(1-T.L))/t0
TU2= (-log(1-T.U))/t0

TL2 = round(TL2,2)
TU2 = round(TU2,2)
```

Realizacją przedziału ufności dla  $\alpha = 0.05$  jest przedział  $[T_L, T_U] = [0.32, 1.3]$ , natomiast dla  $\alpha = 0.01$  przedział  $[T_L, T_U] = [0.25, 1.52]$

## Zadanie 2

Przyjmujemy, że obserwacje czasu do remisji choroby były prowadzone do momentu, w którym u dziesięciu pacjentów zostanie ona zaobserwowana. Dla takich danych wyznaczamy najpierw oszacowania największej wiarygodności średniego czasu do remisji choroby dla pacjentów leczonych lekiem A oraz pacjentów leczonych lekiem B.

```
m=10
n=10
T2_a <- round(m/(sum(grupa_A)+(n-m)*grupa_A[m]),2)
T2_b <- round(m/(sum(grupa_B)+(n-m)*grupa_B[m]),2)
```

Zatem z wyliczeń wynika, że oszacowania największej wiarygodności średniego czasu do remisji w grupie A wynoszą: 0.73 a w grupie B: 0.96.

Następnie dla danych wyznaczamy realizację przedziału ufności na poziomie  $1-\alpha$ , dla odpowiednio dwóch wartości  $\alpha$ : 0.05 i 0.01.

```
m=10
n=10
## dla alfy = 0.05
alfa=0.05
qm_a1 = qgamma(alfa/2,m,m)
TLa <- round((m*qm_a1)/T2_a,2)
qm_a2 = qgamma((1-alfa)/2,m,m)
TUa <-round((m*qm_a2)/T2_a,2)

qm_b1 = qgamma(alfa/2,m,m)
round(TLb <- (m*qm_a1)/T2_b,2)
```

```
## [1] 5
```

```
qm_b2 = qgamma((1-alfa)/2,m,m)
TUb <-round((m*qm_b2)/T2_b,2)
```

Dla  $\alpha=0.05$  realizacjami przedziałów ufności dla grupy A jest przedział  $[6.57, 23.4]$  a dla grupy B:  $[4.9951966, 17.8]$ . Szerokość przedziałów wynika z niewielkiej liczebności próby danych.

Następnie wyznaczamy realizację przedziału ufności dla  $\alpha=0.01$ :

```
m=10
n=10
```

```
## dla alfy = 0.01
alfa=0.01
qm_a1 = qgamma(alfa/2,m,m)
TLa <- round((m*qm_a1)/T2_a,2)
qm_a2 = qgamma((1-alfa/2),m,m)
TUa <-round((m*qm_a2)/T2_a,2)

qm_b1 = qgamma(alfa/2,m,m)
TLb <- round((m*qm_a1)/T2_b,2)
qm_b2 = qgamma((1-alfa/2),m,m)
TUb <- round((m*qm_b2)/T2_b,2)
```

Stąd otrzymujemy, że realizacjami przedziałów ufności dla grupy A jest przedział [5.09, 27.4] a dla grupy B: [3.87, 20.83]

Realizacją przedziału ufności dla  $\alpha = 0.05$  jest przedział  $[T_L, T_U] = [??, ??]$ , natomiast dla  $\alpha = 0.01$  przedział  $[T_L, T_U] = [??, ??]$

### Zadanie 3

Przeprowadzono symulację w celu porównania dwóch estymatorów parametru  $\vartheta$  rozkładu wykładniczego przy danych cenzurowanych I-go typu:

$$\hat{\vartheta} = \frac{R}{T_1} \quad (1)$$

$$\tilde{\vartheta} = -\frac{\log(1 - R/n)}{t_0} \quad (2)$$

gdzie  $R = \sum_{i=1}^n 1(X_i \leq t_0)$  oraz  $T_1 = \sum_{i=1}^R X_{(i)} + t_0(n - R)$ .

Symulację wykonano dla  $\vartheta = 1$ , licznosci prób  $n = 10, 30$  oraz czasów obserwacji  $t_0 = 0.5, 1, 2$ , powtarzając eksperyment  $M = 10,000$  razy. Dla każdego przypadku obliczono obciążenie (Bias) oraz błąd średniokwadratowy (MSE) obu estymatorów.

```
library(knitr)

typ_I <- function(t0,theta,n){
  X<-numeric(n)
  delta <-numeric(n)
  check <- 0

  while (check == 0){
    X<-numeric(n)
    delta <-numeric(n)
    X=rexp(n, 1/theta)
    X <- sort(X)
    for(i in 1:n){
      if(X[i]>t0){
```

```

        X[i] <- t0
        delta[i] <- 0
        check <- 1
      }else{delta[i]<-1}}
    }
    return(data.frame(X = X, delta = delta))
    X <- sort(X)
  }
symulacja <- function(theta,n,t0,M){
  est1 <- numeric(M)
  est2 <- numeric(M)
  for (i in (1:M)){
    dane <- typ_I(t0,theta,n)
    R <- sum(dane$delta)
    T1 <- sum(dane$X)
    est1[i] <- R/T1
    est2[i] <- -log(1-R/n)/t0
  }
  bias1 <- est1-theta
  bias2 <- est2-theta
  mse1 <- bias1^2
  mse2 <- bias2^2
  bias_c1 <- mean(bias1)
  bias_c2 <- mean(bias2)
  mse_c1 <- mean(mse1)
  mse_c2 <- mean(mse2)
  return(c(bias_c1, bias_c2, mse_c1, mse_c2))
}
#symulacja(1,10,1,10000)

n_list <- c(10,30)
t0_list <- c(0.5,1,2)
wyniki <- list(6)
i <- 1
for (n in n_list){
  for (t0 in t0_list){
    wyniki[[i]] <- symulacja(1,n,t0,10000)
    i = i+1
  }
}

wyniki.df <- data.frame(
  n = rep(n_list, each = length(t0_list)),
  t0 = rep(t0_list, times = length(n_list)),
  Bias_Est1 = round(sapply(wyniki, function(x) x[1]), 4),
  Bias_Est2 = round(sapply(wyniki, function(x) x[2]), 4),

```

```

MSE_Est1 = round(sapply(wyniki, function(x) x[3]), 4),
MSE_Est2 = round(sapply(wyniki, function(x) x[4]), 4)
)

kable(wyniki_df,
      booktabs = TRUE,
      col.names = c("n", "t0", "Bias Est1", "Bias Est2", "MSE Est1", "MSE Est2"),
      caption = "Wyniki symulacji dla różnych wartości n i t0")

```

Tabela 1: Wyniki symulacji dla różnych wartości  $n$  i  $t_0$

n	t0	Bias Est1	Bias Est2	MSE Est1	MSE Est2
10	0.5	0.0584	0.0680	0.2987	0.3233
10	1.0	0.0606	0.0847	0.1890	0.2273
10	2.0	-0.0465	-0.0765	0.0793	0.0604
30	0.5	0.0178	0.0203	0.0892	0.0928
30	1.0	0.0226	0.0317	0.0571	0.0675
30	2.0	0.0181	0.0478	0.0392	0.0670

Z przeprowadzonej analizy wynika, że wraz ze wzrostem liczności próby  $n$  obciążenie i MSE obu estymatorów maleją, co potwierdza ich zgodność. Większe wartości  $t_0$  (czyli mniejsze cenzurowanie) prowadzą do dokładniejszych oszacowań. W większości przypadków estymator  $\hat{\vartheta} = R/T_1$  charakteryzuje się mniejszym błędem średniokwadratowym, co wskazuje na jego większą efektywność w porównaniu z estymatorem  $\tilde{\vartheta} = -\log(1 - R/n)/t_0$ .