

Lista 5

Analiza przeżycia

Olga Foriasz, Tomasz Warzecha

2025-10-08

Spis treści

1	Lista 5	1
1.1	Zadanie 1 - Analiza graficzna estymatorów funkcji przeżycia	1
1.2	Zadanie 2 - tworzenie wykresu estymatora Kaplana-Meiera z “ogonem”	3
1.3	Zadanie 3 - oszacowanie wartości funkcji przeżycia	4

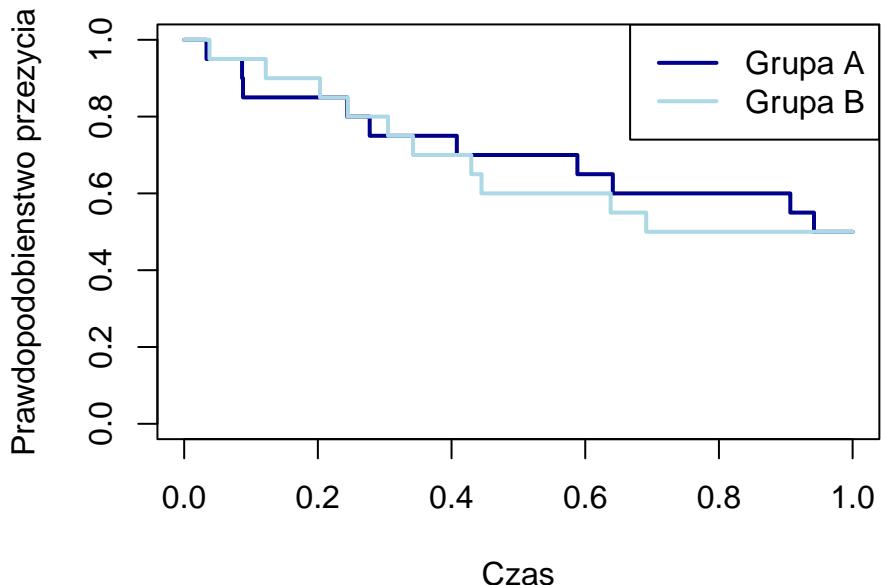
1 Lista 5

1.1 Zadanie 1 - Analiza graficzna estymatorów funkcji przeżycia

Celem zadania było graficzne przedstawienie i porównanie estymatorów funkcji przeżycia dla czasu do remisji choroby w grupach pacjentów leczonych lekiem A oraz lekiem B. Dane pobrano z zadania 3 z listy 2. Wykorzystano dwie metody nieparametryczne:

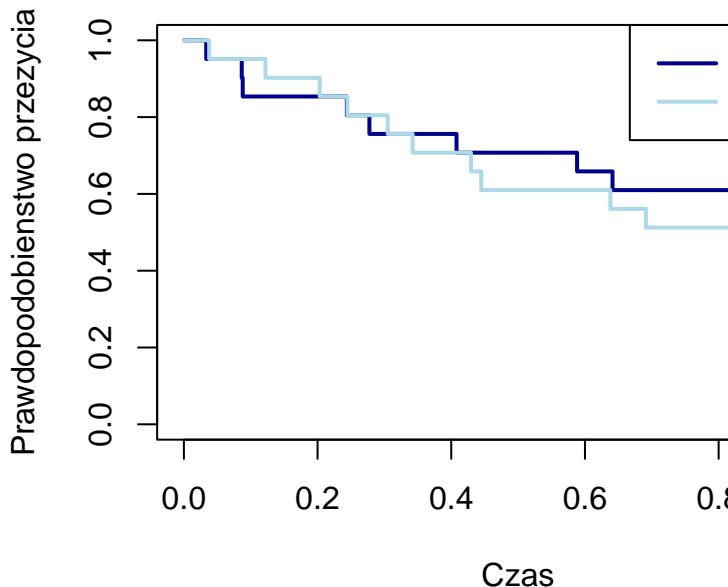
- a) Estymator Kaplana-Meiera (KM) b) Estymator Fleminga-Harringtona (FH)

Estymator Kaplana–Meiera dla grup A i B



Na powyższym wykresie widzimy estymator Kaplana-Meiera dla grup A i B.

Estymator Flemingia–Harringtona dla grup A i B



Teraz wyznaczmy sobie estymator Flemingia-Harringtona:

Na powyższym wykresie widzimy estymator Flemingia-Harringtona dla grup A i B. Zarówno wykres estymatora Kaplana-Meiera, jak i Flemingia-Harringtona, są wizualnie niemal identyczne i prowadzą do tych samych wniosków.

Na podstawie wykresów estymatorów Kaplana–Meiera można zauważyc, że krzywe przeżycia dla grup A i B mają zbliżony przebieg. Początkowo wartości funkcji przeżycia są prawie identyczne, natomiast w środkowym zakresie czasów (około 0.3-0.7) krzywa dla grupy B przebiega nieco niżej, co sugeruje, że pacjenci leczeni lekiem B częściej osiągali remisję wcześniej niż pacjenci z grupy A. Ostatecznie jednak obie krzywe schodzą do podobnego poziomu, co wskazuje, że końcowy odsetek remisji w obu grupach jest zbliżony. Zatem na podstawie otrzymanych wykresów można przypuszczać, że leki A i B wykazują podobne działanie, przy czym lek B może powodować nieco szybsze wystąpienie remisji we wcześniejszym okresie obserwacji.

1.2 Zadanie 2 - tworzenie wykresu estymatora Kaplana-Meiera z “ogonem”

Na początku stworzymy sobie funkcję do tworzenia wykresu estymatora Kaplana-Meiera z “ogonem” estymowanym zgodnie z propozycją Browna, Hollandera i Kowara. W tym celu na początku wyznaczmy sobie estymator Kaplana-Meiera za pomocą funkcji `survfit()` dla $t \in (0, t^+]$, następnie dla $t \in (t^+, 2t^+)$ wyznaczmy sobie “ogon” naszego estymatora za pomocą wzoru:

$$\hat{S}(t) = \exp \left[\frac{\ln \hat{S}(t^+)}{t^+} t \right],$$

```
est <- function(time,km,t0){
  y <- numeric(length(time))
  i <- 1
  for (t in time){
    y[i] <- exp(log(min(km))*t/t0)
    i = i+1
  }
  return(y)
}

wykres <- function(dane,t0,nazwa_wykresu){
  km_fit <- survfit(Surv(czas,delta)^-1, dane)
  ogonx <- seq(from = (t0), to = 2*t0, by = 0.1)
  ogony <- est(ogonx,km_fit$surv,t0)
  plot(km_fit, col = "darkblue",conf.int = FALSE,
    xlab = "Czas", ylab = "Prawdopodobieństwo przeżycia",
    main = nazwa_wykresu,
    xlim = c(0, t0*2))
  lines(ogony, col = "lightblue", lwd = 2)
  legend("topright",
    legend = c("Estymator KM", "'ogon'"),
    col = c("darkblue", "lightblue"),
    lwd = 2)
}
```

Teraz mając funkcję tworzącą wykresy, narysujemy sobie wykres naszego estymatora dla danych z zad.3 z listy 2.

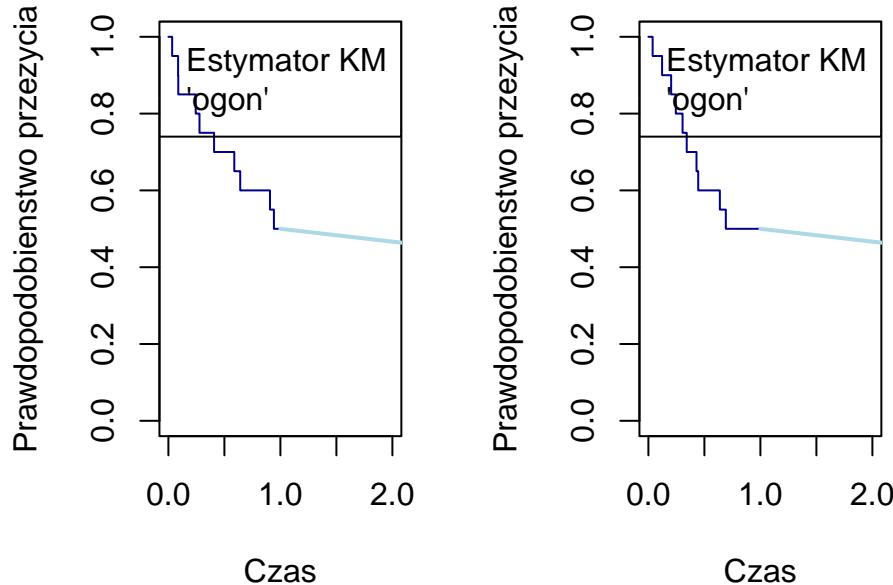
```

par(mfrow = c(1,2))
wykres(dane_A,1,"Estymator KM z ogonem dla gr. A")

wykres(dane_B,1,"Estymator KM z ogonem dla gr. B")

```

Estymator KM z ogonem dla estymator KM z ogonem dla



Na powyższych wykresach możemy zobaczyć wartości estymatora K-M z ogonem dla grupy A i B. Jak widać powyższe wykresy znacznie się nie różnią, ogon estymatora Kaplana–Meiera pokazuje dalszy spadek funkcji przeżycia po ostatnich zaobserwowanych zdarzeniach, co oznacza, że prawdopodobieństwo przeżycia (braku remisji) nadal maleje w miarę upływu czasu, mimo braku nowych obserwacji zdarzeń.

1.3 Zadanie 3 - oszacowanie wartości funkcji przeżycia

```

typ_I <- function(t0, alfa, lambda, n){
  p <- runif(n)
  X<-numeric(n)
  delta <-numeric(n)
  for(i in 1:n){
    X[i]=(-(1/lambda))*log(1-(p[i])^(1/alfa))
    if(X[i]>t0){
      X[i] <- t0
      delta[i] <- 0
    }else{delta[i]<-1}
  }
  return(data.frame(X = X, delta = delta))
}

est <- function(time,km,t0){

```

```

y <- numeric(length(time))
i <- 1
for (t in time){
  y[i] <- exp(log(min(km))*t/t0)
  i = i+1
}
return(y)
}

est_KM_ogon <- function(dane,t0){
  km_fit <- survfit(Surv(X,delta)^~1, dane)
  ogonx <- seq(from = (t0+0.1), to = 2*t0, by = 0.1)
  ogony <- est(ogonx,km_fit$surv,t0)
  fy <- c(km_fit$surv, ogony)
  fx <- c(km_fit$time, ogonx)
  funkcja <- data.frame(x = fx, y = fy)
  xt0 <- funkcja$y[funkcja$x == t0]
  x2t0 <- funkcja$y[funkcja$x == 2*t0]
  return(c(xt0,x2t0))
}

par(mfrow = c(1,2))

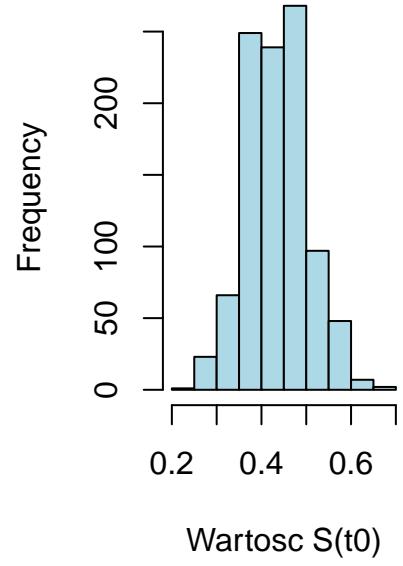
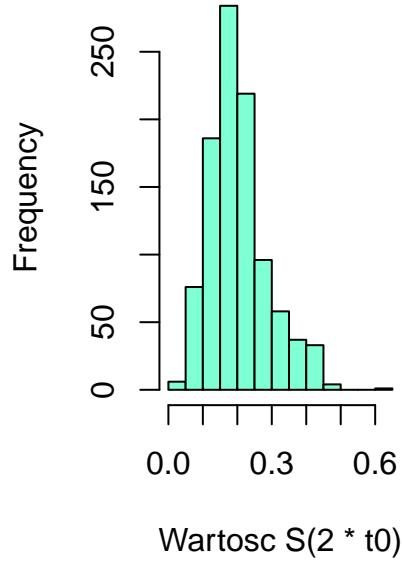
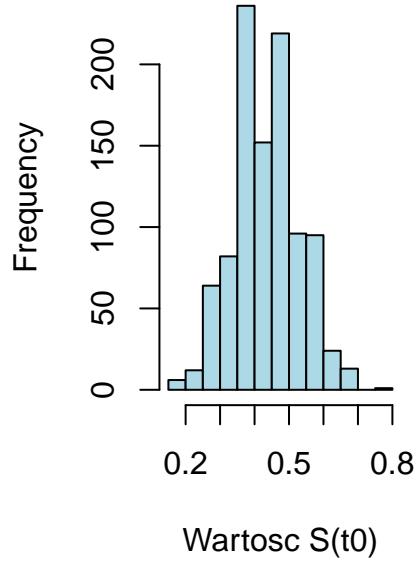
histogramy <- function(alfa,lambda,t0,m,n_list){
  for(n in n_list){
    st0 <- numeric(m)
    s2t0 <- numeric(m)
    for(i in (1:m)){
      dane <- typ_I(t0,alfa,lambda,n)
      s <- est_KM_ogon(dane,t0)
      st0[i]<- s[1]
      s2t0[i]<- s[2]
    }
    hist(st0, col = "lightblue", main = paste("n =", n, " | Estymator S(t0)"), xlab = "Wartość")
    hist(s2t0, col = "aquamarine",main = paste("n =", n, " | Estymator S(2 * t0)"), xlab = "Wa
  }
}

n_list <- c(30,50,100)
alfa <- 4
lambda <- 1
t0 <- sqrt(alfa)/lambda
m <- 1000

histogramy(alfa,lambda,t0,m,n_list)

```

n = 30 | Estymator S(t0) **n = 30 | Estymator S(2 * t0)** **n = 50 | Estymator S(t0)**



n = 100 | Estymator S(t0) **n = 100 | Estymator S(2 * t0)**

